



機器學習 期末專題


109705012 嚴臨

111705068 王子儀

Overview

- Introduction
- Model
- Bottleneck
- Outcome Analysis
- Problems
- Conclusions






Introduction

General concept

- Do images classification with small amount of data.

Basic model

- CLIP
- Convnext_tiny



Model

CLIP

使用 open_clip_torch 中的
"ViT-B-32" 預訓練模型。

只訓練 ln_post 和 proj 層
最後加上 Linear 分類器

Convnext_tiny

使用了timm的
預訓練模型

只訓練head分類




Transfer Learning


$$\begin{array}{ccc} \mathcal{X}_S \ni X_S & \xrightarrow[\substack{f_S^* \in \arg \min_{f \in A_S} \mathcal{L}_S(f_S)}]{\text{Pretrained model } f_S^*} & f_S^*(X_S) \in \mathcal{Y}_S \\ \uparrow T^X & & \downarrow T^Y \\ \mathcal{X}_T \ni X_T & \xrightarrow[\substack{f_T^* \in \arg \min_{f \in A_T} \mathcal{L}_T(f_T)}]{\text{Direct learning}} & f_T^*(X_T) \in \mathcal{Y}_T \end{array}$$




CLIP




CLIP




CLIP




ConvNeXt



(a)



(b)




(c)

Convnext

$$\begin{array}{ccc} \mathcal{X}_S \ni X_S & \xrightarrow[\substack{f_S^* \in \arg \min_{f \in A_S} \mathcal{L}_S(f_S)}]{\text{Pretrained model } f_S^*} & f_S^*(X_S) \in \mathcal{Y}_S \\ \uparrow T^X & & \downarrow T^Y \text{ head} \\ \mathcal{X}_T \ni X_T & \xrightarrow[\text{Direct learning}]{\substack{f_T^* \in \arg \min_{f \in A_T} \mathcal{L}_T(f_T)}} & f_T^*(X_T) \in \mathcal{Y}_T \end{array}$$

Ensemble



Weighting Averaging

Bottleneck-Emsamble

CLIP Fine-tuning:	85.00%	(最佳epoch: 49)
Standard timm:	73.33%	(最佳epoch: 24)
Optimized Ensemble:	88.33%	



Bottleneck-Data Argument

```
=====
CLIP Fine-tuning:      86.67% (最佳epoch: 34)
Standard timm:        73.33% (最佳epoch: 14)
Optimized Ensemble:    85.00%
```



Problems

- How to achieved the optimal balance between model performance and the number of parameters.
 - 參數量大 → 更能擬合訓練集, 但更容易過擬合 → 驗證集準確率下降
 - 參數量小 → 泛化能力可能好, 但擬合能力不足 → 訓練集也學不好
- 在樣本數有限的情況下, 我們的方法透過
 - 控制參數量(例如只微調部分層)
 - 使用早停策略
 - 引入正則化與 ensemble 技術



Conclusions

- 在 **樣本數不足** 的情境下，透過 **使用預訓練模型** (如 CLIP 與 ConvNeXt) 進行微調 (**fine-tuning**)，能夠顯著提升模型表現。
- 然而，預訓練模型效果良好的前提包含以下幾點條件限制：
 1. **目標任務與預訓練任務之間有語意相關性** （例如 CLIP 用於圖片分類仍能受益）。
 2. **資料分布不與預訓練模型的訓練資料相差太遠** （否則需更多微調）。
 3. **還是需搭配適當的資料增強與正則化策略，避免小樣本下訓練不穩定。**
- 透過 **模型集成 (Ensemble)** 技術，將 CLIP 與 ConvNeXt 模型的預測結果以加權平均的方式結合，並使用驗證集進行權重優化。此方式顯示：
 1. **不同架構模型提供互補的特徵表示能力。**
 2. **加權 ensemble 能在不增加額外資料的情況下提升準確率，並增強模型的穩健性。**



Reference

<https://arxiv.org/abs/2103.00020>

<https://arxiv.org/abs/2201.03545>

<http://violin-tao.blogspot.com/2018/01/ml-ensemble.html>



Thank's For Watching

